


# SVM 支持向量机

**目标:** 找到区分两类的超平面 (hyper plane) 使边际 (margin) 最大化。




区分两类可以有无数个超平面, 但 SVM 要使边际最大。

Max Margin Hyperplane (MMH).

类别: 线性可区分  
Linear separable



线性不可区分  
Linear inseparable.



## Linear separable

**定义超平面:**  $WX + b = 0$

$$W = (w_1, w_2, \dots, w_n) \quad X = (x_1, x_2, \dots, x_n)^T$$

先从简单的 2-D 情况讨论。


$$w_1 x_1 + w_2 x_2 + b = 0 \quad \text{把 } b \text{ 看成 } w_0.$$

$$\text{即 } w_0 + w_1 x_1 + w_2 x_2 = 0 \Rightarrow \text{hyper plane.}$$

即  $w_0 + w_1x_1 + w_2x_2 = 0 \Rightarrow \text{hyper plane.}$

在 hyper plane 上方的点:  $w_0 + w_1x + w_2x > 0.$

在 hyper plane 下方的点:  $w_0 + w_1x + w_2x < 0.$



调整 weight, 使超平面两边距离.

$$H_1: w_0 + w_1x_1 + w_2x_2 \geq 1 \quad (y=1)$$

$$H_2: w_0 + w_1x_1 + w_2x_2 \leq -1 \quad (y=-1)$$

Support vector  
(支持向量)

$$y_i(w_0 + w_1x_1 + w_2x_2) \geq 1 \quad (*)$$

hyper plane 到  $H_1$  或  $H_2$  上的距离为  $\frac{1}{\|w\|}$   $\rightarrow w$  的范数.

$$w = (w_1, w_2, \dots, w_n)$$

$$\|w\| = \sqrt{w_1^2 + w_2^2 + \dots + w_n^2}$$

$$\therefore \text{上下边距离为 } \frac{2}{\|w\|}$$

把式变为有限制的凸优化问题 (convex quadratic optimization)

利用 Karush-Kuhn-Tucker (KKT) 条件和拉格朗日公式, 可以推出 SVM 可被表示为决策边界 (decision boundary)

$$d(x^T) = \sum_{i=1}^L y_i \alpha_i x_i x^T + b_0.$$

其中,  $x_i$  为支持向量点,  $y_i$  是  $x_i$  的类别标记.

$x^T$  是被测试的实例,  $\alpha_i$  是拉代方程中的参数.

$L$  是支持向量的个数.


Linear inseparable

数据集在空间中不能被对应的超平面分开

数据集在空间中不能被对应的超平面分开


如何处理?

用非线性映射把低维数据集中的向量点转化到更高维度的空间中。



在更高维的空间中找到一个线性超平面来区分数据集。

例:



如何使用非线性映射转化?

如: 3维向量  $X = (x_1, x_2, x_3)$

$\Downarrow$

6维向量  $\Phi = (\varphi_1, \varphi_2, \varphi_3, \varphi_4, \varphi_5, \varphi_6)$

其中:  $\varphi_1 = x_1$   $\varphi_2 = x_2$   $\varphi_3 = x_3$   $\varphi_4 = x_1 \cdot x_1$   $\varphi_5 = x_1 \cdot x_2$   $\varphi_6 = x_1 \cdot x_3$

new hyper plane

$d(\Phi) = w \cdot \Phi + b$  线性的超平面

通过 KKT 和拉格朗日公式求得  $w$  和  $b$ .

$$\therefore d(\Phi) = w_1 x_1 + w_2 x_2 + w_3 x_3 + w_4 (x_1)^2 + w_5 x_1 x_2 + w_6 x_1 x_3 + b.$$

$$= w_1 \varphi_1 + w_2 \varphi_2 + w_3 \varphi_3 + w_4 \varphi_4 + w_5 \varphi_5 + w_6 \varphi_6 + b.$$

核方法 (kernel trick).

用核方法来进行非线性映射, 并降低内积时的复杂度。

$$K(x_i, x_j) = \Phi(x_i) \cdot \Phi(x_j)$$



$$K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$$

常用的核函数

**h 度多项式核函数** (polynomial kernel of degree h)

$$K(x_i, x_j) = (x_i \cdot x_j + 1)^h$$

**高斯径向基核函数** (Gaussian radial basis function kernel)

$$K(x_i, x_j) = e^{-\|x_i - x_j\|^2 / 2\sigma^2} \quad (\sigma \text{ 为方差}).$$

**S 型核函数** (sigmoid function kernel)

$$K(x_i, x_j) = \tanh(kx_i \cdot x_j - \delta)$$

大多数情况下, 图像分类用高斯径向基核函数  
而文字分类不用高斯径向基核函数.

**例:** Example of kernel function

$$X = (x_1, x_2, x_3) \quad Y = (y_1, y_2, y_3)$$

$$f(x) = (x_1x_1, x_1x_2, x_1x_3, x_2x_1, x_2x_2, x_2x_3, x_3x_1, x_3x_2, x_3x_3)$$

$$K(X, Y) = (\langle X, Y \rangle)^2$$

$$\text{假设 } X = (1, 2, 3) \quad Y = (4, 5, 6)$$

$$f(x) = (1, 2, 3, 2, 4, 6, 3, 6, 9)$$

$$f(y) = (16, 20, 24, 20, 25, 30, 24, 30, 36)$$

$$\langle f(x), f(y) \rangle = 16 + 40 + 72 + 48 + 100 + 180 + 72 + 180 + 324 = 1024.$$

而使用  $K(x, y)$

↓

$$K(X, Y) = (4 + 10 + 18)^2 = 1024$$

从而大大简化了计算量.

从而大大简化了计算量。

SVM的扩展应用：多类分类

第一类 | 其他类  $\Rightarrow$  第二类 | 其他类  $\dots$  第n类 | 其他类。

One | rest.